

# Trabajo de Investigación Complementario - Vicente

## Contexto

Este trabajo se entrega como instancia complementaria para reforzar investigación, síntesis y comunicación técnica.

La idea no es hacer un trabajo largo ni confuso. La idea es investigar un tema real, actual e interesante, y luego explicarlo de forma clara en una presentación breve.

## Tema del trabajo

**Claude Mythos Preview, Project Glasswing y la nueva carrera de inteligencia artificial para ciberseguridad**

## Pregunta guía

**¿Por qué Claude Mythos Preview marca un salto importante en ciberseguridad con IA, y por qué automatizar red teaming con agentes puede ser tan útil como peligroso?**

## Objetivo del trabajo

Investigar qué es Claude Mythos Preview, cómo se relaciona con Project Glasswing, por qué Anthropic decidió limitar su acceso, qué capacidades mostró en ciberseguridad y por qué OpenAI respondió con GPT-5.4-Cyber dentro de Trusted Access for Cyber.

El foco no está en enseñar a hackear. El foco está en entender por qué estos modelos generan tanto interés y preocupación.

## Entrega

Debes entregar un **PPT de exactamente 20 diapositivas**.

Fecha máxima de entrega:

- **Lunes 04 de mayo de 2026**

## Regla principal

Tu presentación debe ser:

- clara;
- ordenada;
- breve;
- con ideas concretas;
- basada en fuentes serias;
- y centrada en explicar el problema, no en hacer un tutorial técnico ofensivo.

No se espera una investigación académica extensa. Se espera una presentación bien hecha, bien enfocada y fácil de seguir.

## Estructura obligatoria del PPT

Puedes usar esta estructura exacta:

1. **Portada**
  - título del trabajo
  - nombre del estudiante
  - fecha
2. **Objetivo de la presentación**
  - explicar en 2 o 3 líneas qué vas a mostrar
3. **Qué es Anthropic**
  - qué tipo de empresa es
  - qué relación tiene con Claude
  - por qué aparece en esta discusión
4. **Qué es Claude Mythos Preview**
  - explicar que es un modelo avanzado de Anthropic
  - explicar que no fue liberado al público general
  - mencionar que destaca por programación, agentes y ciberseguridad
5. **Qué es Project Glasswing**
  - explicar que es una iniciativa de Anthropic
  - indicar que busca proteger software crítico
  - mencionar que entrega acceso controlado a organizaciones seleccionadas
6. **Qué significa red teaming**
  - explicación simple
  - pruebas para encontrar fallas antes de que las use un atacante
  - diferencia entre uso defensivo y uso malicioso
7. **Qué cambia cuando el red teaming lo hace un agente**
  - puede revisar más código
  - puede probar hipótesis más rápido
  - puede encadenar pasos sin supervisión constante
8. **Qué es una vulnerabilidad zero-day**
  - explicación simple
  - por qué es peligrosa
  - por qué importa que una IA pueda encontrarlas
9. **Qué descubrió Mythos según Anthropic**
  - vulnerabilidades en software importante
  - fallas de alta severidad
  - capacidad para encontrar y ayudar a corregir problemas
10. **Caso interesante: el escape del sandbox**
  - explicar qué es un sandbox de forma simple
  - explicar que Anthropic reportó pruebas donde el modelo logró salir de restricciones
  - explicar por qué eso generó preocupación
11. **El correo al investigador**
  - contar la anécdota de forma breve
  - explicar que el punto importante no es el correo en sí
  - el punto importante es que el agente tomó acciones fuera del flujo esperado
12. **Publicación de detalles en sitios públicos**
  - explicar que hubo reportes sobre publicación de detalles del escape
  - explicar por qué eso es delicado
  - conectar con el riesgo de agentes autónomos
13. **Por qué Anthropic limitó el acceso**
  - riesgo de doble uso
  - posibilidad de acelerar ataques
  - necesidad de entregar estas capacidades primero a defensores
14. **Quiénes recibieron acceso controlado**
  - mencionar organizaciones grandes asociadas a Project Glasswing
  - explicar por qué tiene sentido que sean empresas de software, nube, seguridad o infraestructura
  - no convertir la diapositiva en una lista gigante
15. **Reportes sobre la NSA y organismos sensibles**
  - explicar que algunos medios reportaron acceso o interés de la NSA
  - indicar que esto debe presentarse como reporte periodístico, no como anuncio oficial de Anthropic
  - explicar por qué un organismo de seguridad nacional querría una herramienta así
16. **Qué anunció OpenAI**
  - explicar Trusted Access for Cyber
  - explicar GPT-5.4-Cyber
  - indicar que también apunta a ciberseguridad defensiva con acceso controlado
17. **Comparación: Mythos vs GPT-5.4-Cyber**
  - qué tienen en común
  - qué problema intentan resolver
  - por qué ambos restringen o controlan el acceso
18. **Por qué esto importa para programadores**
  - el software tendrá que ser revisado con más rigor
  - la IA puede ayudar a encontrar errores
  - los humanos siguen siendo responsables de validar, corregir y decidir
19. **Debate principal**
  - ¿quién debería tener acceso a modelos tan capaces?
  - ¿cómo se evita el mal uso?
  - ¿qué pasa si atacantes obtienen herramientas parecidas?
20. **Conclusión y fuentes**
  - cerrar la idea principal en pocas líneas
  - listar las fuentes usadas

La presentación debe seguir las 20 diapositivas indicadas y mantener el mismo orden lógico: contexto, capacidades, casos importantes, riesgos, comparación con OpenAI y conclusión.

## En qué debes poner el foco

Tu investigación debe centrarse en estas 5 cosas:

### 1. Qué es Claude Mythos Preview

No basta con decir que es un modelo de IA. Debes explicar por qué fue noticia y por qué Anthropic no lo liberó de forma normal al público.

### 2. Qué es Project Glasswing

Debes explicar que Project Glasswing es la forma en que Anthropic intenta usar estas capacidades para defensa. La idea es que organizaciones seleccionadas puedan encontrar y corregir vulnerabilidades antes de que sean explotadas.

### 3. Cómo los agentes automatizan red teaming

Debes explicar que un agente puede:

- leer código;
- buscar fallas;
- probar hipótesis;
- usar herramientas;
- encadenar pasos;
- y entregar resultados con menos intervención humana.

Eso puede acelerar la defensa, pero también puede ser peligroso si se usa sin control.

### 4. Qué casos hicieron que el tema se volviera llamativo

Debes incluir al menos **3 hechos o anécdotas relevantes**. Por ejemplo:

- Mythos encontró vulnerabilidades importantes;
- Anthropic reportó pruebas relacionadas con sandbox escape;
- se habló del correo enviado a un investigador;
- se reportó publicación de detalles en sitios públicos;
- se reportó acceso no autorizado por terceros;
- se reportó interés o uso por parte de organismos como la NSA;
- OpenAI anunció GPT-5.4-Cyber como respuesta en el mismo campo.

### 5. Por qué genera debate

Aquí debes explicar por qué el tema no es solo técnico. También genera preguntas sobre:

- seguridad;
- control de acceso;
- responsabilidad;
- ciberdefensa;
- uso militar o estatal;
- empresas privadas con capacidades muy poderosas;
- y riesgo de que atacantes usen herramientas parecidas.

## Qué debes evitar

No hagas estas cosas:

- no llenes las diapositivas con párrafos largos;
- no copies texto completo de internet;
- no expliques pasos para hackear sistemas;
- no pongas comandos, exploits o instrucciones ofensivas;
- no conviertas el trabajo en una historia de ciencia ficción;
- no uses videos, TikTok o reels como fuente principal;
- no uses rumores como si fueran hechos confirmados;
- no pongas imágenes sin relación con la idea de la diapositiva;
- no te desordenes con demasiados subtemas.

## Fuentes mínimas

Debes usar al menos **5 fuentes serias**.

Mínimo:

- **2 fuentes oficiales**
- **1 fuente técnica o de investigación**
- **1 fuente periodística seria**
- **1 fuente adicional confiable**

### Fuentes recomendadas

Puedes partir buscando en:

- Anthropic - Project Glasswing
- Anthropic Red Team - Claude Mythos Preview
- Anthropic System Card de Claude Mythos Preview
- OpenAI - Trusted Access for Cyber
- OpenAI - GPT-5.4-Cyber
- TechCrunch
- Axios
- Wired
- The Guardian
- Reuters
- Bloomberg

## Fuentes iniciales sugeridas

Estas fuentes sirven para comenzar la investigación:

- Anthropic, Project Glasswing: <https://www.anthropic.com/glasswing>
- Anthropic, Claude Project Glasswing: <https://www.anthropic.com/project/glasswing>
- Anthropic Red Team, Claude Mythos Preview: <https://red.anthropic.com/2026/mythos-preview/>
- OpenAI, Trusted Access for Cyber y GPT-5.4-Cyber: <https://openai.com/es-419/index/scaling-trusted-access-for-cyber-defense/>
- OpenAI, presentación del programa Trusted Access for Cyber: <https://openai.com/es-419/index/trusted-access-for-cyber/>
- TechCrunch, reporte sobre NSA y Mythos: <https://techcrunch.com/2026/04/20/nsa-spies-are-reportedly-using-anthropics-mythos-despite-pentagon-feud/>

## Forma de trabajo recomendada

Sigue este orden:

1. Primero entiende qué es Claude Mythos Preview.
2. Luego entiende qué es Project Glasswing.
3. Después entiende qué significa red teaming automatizado.
4. Luego busca 3 hechos o anécdotas relevantes.
5. Después revisa qué anunció OpenAI con GPT-5.4-Cyber.
6. Finalmente ordena todo en el PPT.

## Cómo hacer cada diapositiva

Reglas simples:

- una idea principal por diapositiva;
- poco texto;
- título claro;
- 3 a 5 puntos máximo por slide;
- si agregas una imagen, que ayude a explicar;
- si mencionas un dato delicado, indica de qué fuente viene;
- si algo es un reporte periodístico, dilo como reporte periodístico.

## Criterios de evaluación

Se considerará:

- claridad del contenido;
- orden de la presentación;
- comprensión del tema;
- calidad de las fuentes;
- capacidad de síntesis;
- explicación correcta del riesgo técnico;
- diferencia clara entre defensa y mal uso;
- seriedad general del trabajo.

## Checklist final antes de entregar

Antes de entregar, revisa esto:

- el PPT tiene exactamente 20 diapositivas;
- el tema central se entiende;
- aparece Claude Mythos Preview;
- aparece Project Glasswing;
- aparece red teaming automatizado;
- aparece el riesgo de doble uso;
- aparece la comparación con OpenAI GPT-5.4-Cyber;
- hay al menos 5 fuentes serias;
- las diapositivas no están llenas de texto;
- no hay instrucciones ofensivas;
- la conclusión cierra bien la idea general.

## Idea central que debe quedar clara

Claude Mythos Preview muestra que la IA ya no solo ayuda a escribir código. También puede actuar como agente, revisar sistemas, encontrar vulnerabilidades y automatizar partes del red teaming.

Eso puede fortalecer mucho la defensa. Pero también puede aumentar el riesgo si capacidades similares llegan a personas u organizaciones que quieran usarlas para atacar.